МИНОБРНАУКИ РОССИИ
САНКТ–ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра вычислительной техники

ОТЧЕТ

по лабораторной работе №2

по дисциплине «Машинное обучение»

Тема: «Кластеризация»

Студентка гр. 2387 _____ Лавренова Ю.Д.

Преподаватель _____ Турсуков Н.О.

Санкт–Петербург
2026

Оглавление

Цель работы 3

Задачи 3

Теория 3

Выполнение работы 6

1. Предварительная обработка данных 6

2. Обучение моделей кластеризации 7

a. Метод К-средних 7

b. DBSCAN 9

c. Иерархическая кластеризация 12

3. Провести оценку моделей 14

a. Экспертная оценка 14

b. Сравнение разбиения на классы с помощью кластеризации с реальными. 16

c. Визуализация предсказанных значений 18

d. Провести кросс-валидацию устойчивости кластеров через многократную подвыборку данных 20

Выводы 22

Цель работы

Закрепить навыки предобработки данных, применить методы машинного обучения для решения задач кластеризации.

Задачи

1. Провести цикл предобработки данных
2. Провести обучение моделей методами кластеризации:

a. метод К-средних: Подбор оптимального числа кластеров k с использованием метода локтя или силуэтного анализа. Протестировать разные инициализации (k-means++ и тд). Реализовать ансамблевую кластеризацию на основе нескольких запусков K-Means с разной инициализацией.

b. DBSCAN: Подбор гиперпараметров при помощи анализа k-расстояний. Исследовать чувствительность алгоритма к шуму и выбросам.

c. Иерархическая кластеризация: Провести кластеризацию с разными метриками расстояния. Определить оптимальное число кластеров с помощью дендрограммы. Сравнить время выполнения при увеличении объема данных (масштабируемость)

3. Провести оценку моделей

a. Экспертная оценка

b. Сравнение разбиения на классы с помощью кластеризации с реальными.

c. Визуализация предсказанных значений

d. Провести кросс-валидацию устойчивости кластеров через многократную подвыборку данных

Теория

Кластеризация относится к методам обучения без учителя, основной целью которых является разделение объектов на группы (кластеры) на основе их сходства по заданным признакам.

Метод K-Means

Метод K-Means (метод K-средних) является одним из наиболее распространенных алгоритмов кластеризации. Его целью является разделение набора объектов на заранее заданное количество k кластеров.

Каждому кластеру соответствует центр, называемый центроидом. Алгоритм стремится расположить центроиды таким образом, чтобы объекты внутри одного кластера были максимально похожи друг на друга, а объекты различных кластеров – различались.

Работа алгоритма состоит из следующих основных этапов:

1. задается количество кластеров k;
2. выбираются начальные положения центроидов;
3. каждый объект относится к ближайшему центроиду;
4. для каждого кластера пересчитывается положение центра как среднее значение всех объектов, входящих в кластер;
5. этапы распределения и пересчета повторяются до достижения сходимости.

Основной критерий, который минимизирует K-Means, представляет собой сумму квадратов расстояний от объектов до центроидов своих кластеров.

Преимуществами метода являются высокая скорость работы, простота реализации и хорошая масштабируемость. К недостаткам относятся необходимость заранее задавать число кластеров и чувствительность к выбросам и начальному расположению центроидов.

Алгоритм DBSCAN

DBSCAN – это алгоритм кластеризации, основанный на плотности распределения объектов. В отличие от K-Means, он не требует заранее задавать количество кластеров.

Название DBSCAN происходит от Density-Based Spatial Clustering of Applications with Noise, то есть плотностной кластеризации пространственных данных с возможностью выделения шума.

Основными параметрами алгоритма являются:

1. eps – радиус окрестности объекта;
2. min_samples – минимальное количество объектов в окрестности, необходимое для формирования плотной области.

На основе этих параметров объекты можно условно разделить на три группы:

1. ядровые точки – находятся в области достаточной плотности;
2. граничные точки – расположены рядом с плотной областью, но сами не удовлетворяют условию плотности;
3. шумовые точки – не относятся ни к одному кластеру.

Преимуществом DBSCAN является возможность выделять кластеры сложной формы и автоматически обнаруживать выбросы. Кроме того, число кластеров определяется структурой данных.

Основным недостатком является чувствительность к выбору параметров eps и min_samples. При слишком малом eps большое количество объектов может быть отнесено к шуму, а при слишком большом – отдельные кластеры могут объединиться.

Иерархическая кластеризация

Иерархическая кластеризация формирует систему вложенных кластеров. Результат работы алгоритма может быть представлен в виде дендрограммы – древовидной структуры, показывающей последовательность объединения или разделения объектов.

Существует два основных подхода:

1. агломеративный – каждый объект первоначально рассматривается как отдельный кластер, после чего наиболее близкие группы постепенно объединяются;
2. дивизивный – все объекты первоначально принадлежат одному кластеру, а затем последовательно разделяются.

На практике наиболее часто используется агломеративная кластеризация.

Результат иерархической кластеризации зависит от способа измерения расстояния между объектами и правила определения расстояния между кластерами.

К распространенным метрикам относятся:

1. евклидово расстояние – наиболее распространенная мера прямого расстояния между объектами;
2. манхэттенское расстояние – сумма абсолютных разностей координат;
3. другие метрики, выбор которых зависит от типа данных.

Для определения расстояния между группами объектов используются различные методы связи:

1. single linkage – минимальное расстояние между объектами двух кластеров;
2. complete linkage – максимальное расстояние;
3. average linkage – среднее расстояние между объектами;
4. Ward linkage – объединение кластеров, при котором минимально увеличивается внутрикластерная дисперсия.

Выполнение работы

1. Предварительная обработка данных

Проведем очистку и подготовку данных для проведения кластеризации. Для этого удалим неинформативные колонки Date и Day. Также удаляем колонки "Sub_Category", "Product", которые могут приводить к переобучению. После этого размерность данных стала (19999, 14). Следующим этапом удалим дубликаты и пустые строки. Итоговый датасет:

```
Month               18021
Year                18021
Customer_Age        18021
Age_Group           18021
Customer_Gender     18021
Country             18021
State               18021
Product_Category    18021
Order_Quantity      18021
Unit_Cost           18021
Unit_Price          18021
```

```
Profit              18021
Cost                18021
Revenue             18021
dtype: int64
```

Выбранный датасет является несбалансированным. Делим все данных на обучающую и тестовую выборки в процентах 80% и 20% соответственно.

Для того, чтобы привести данные к сбалансированному виду, написан скрипт на основе алгоритма SMOTE-NC. В результате получено:

```
Train до балансировки:
Product_Category
Accessories    8950
Bikes          3269
Clothing       2160
Name: count, dtype: int64

Test — исходное распределение:
Product_Category
Accessories    2238
Bikes           817
Clothing        540

Train после балансировки:
Clothing       8950
Accessories    8950
Bikes          8950
Name: count, dtype: int64

Размер train после балансировки: (26850, 86)
Размер test: (3595, 86)
```

2. Обучение моделей кластеризации

а. Метод К-средних

Для реализации данного метода необходимо подобрать оптимальное число кластеров. Для этого используется 2 метода: метод локтя и силуэтного анализа, которые помогают оценить качество кластеризации. Результат прогона 2-10 кластеров со значениями метрик приведены на рисунке 1.

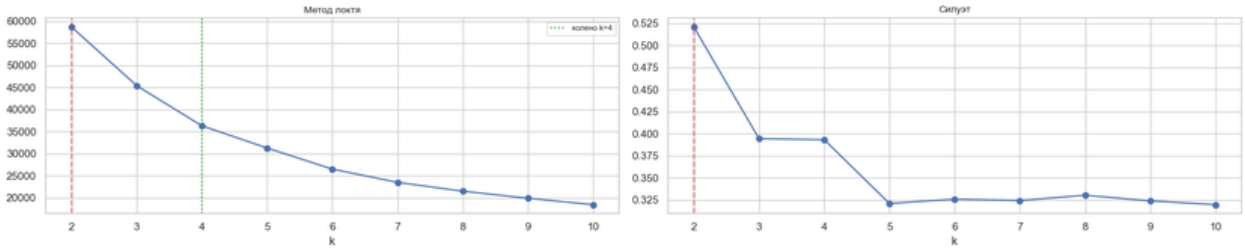


Рисунок 1 – Результат подбора числа кластеров

Исходя из результатов, получено, что оптимальное число кластеров 2. При k=2 коэффициент силуэта максимален (0,521), при k=3 и k=4 он падает до

0,39, а при k≥5 держится около 0,32. Инерция монотонно убывает, четкого «локтя» на кривой нет: формальный поиск излома дает k=4, но выраженного перегиба нет. Поэтому выбор сделан по силуэту, k=2.

Далее протестируем различные инициализации для метода по критериям инерции, ARI, силуэту. Результат представлен на рисунке 2.

init	inertia_mean	inertia_std	inertia_min	inertia_max	iters_mean	time_mean	ARI_mean	ARI_std	silhouette_mean	share_best
farthest-first	58681.8667	0.0008	58681.8666	58681.8701	5.20	0.0113	0.5704	0.0	0.5208	1.0
k-means++	58681.8667	0.0008	58681.8666	58681.8701	3.10	0.0114	0.5704	0.0	0.5208	1.0
random	58681.8671	0.0013	58681.8666	58681.8701	3.65	0.0111	0.5704	0.0	0.5208	1.0

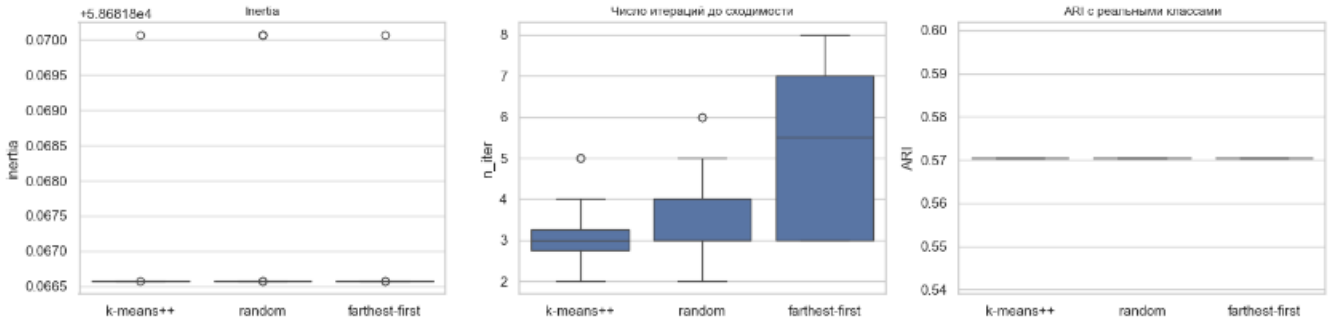


Рисунок 2 – Результат сравнений инициализации K-Means

Все три инициализации (k-means++, random, farthest-first) сошлись к одной инерции 58 681,87 и одинаковым ARI (0,5704) и силуэту (0,5208). Доля запусков, достигших лучшего оптимума, равна 100%. Различается только число итераций: в среднем 3,1 для k-means++, 3,65 для random и 5,2 для farthest-first. Время обучения одинаково, около 0,011 с. Структура данных выражена настолько четко, что результат от инициализации не зависит.

Для повышения устойчивости результатов реализована ансамблевая кластеризация. Выполнено 20 запусков K-Means с чередованием способов инициализации k-means++, random и farthest-first. Для каждого запуска используется один набор начальных центров, то есть n_init=1. Далее рассчитывается матрица согласия. Для каждой пары объектов определяется доля запусков, в которых эти объекты попали в один и тот же кластер.

Запуск	Инициализация	Silhouette	ARI vs y
#1	k-means++	0.5208	0.5807
#2	random	0.5208	0.5807
#3	farthest-first	0.5208	0.5807
#4	k-means++	0.5208	0.5807
#5	random	0.5208	0.5807
#6	farthest-first	0.5208	0.5807
#7	k-means++	0.5208	0.5807
#8	random	0.5208	0.5807
#9	farthest-first	0.5208	0.5807
#10	k-means++	0.5208	0.5807
#11	random	0.5209	0.5817
#12	farthest-first	0.5208	0.5807
#13	k-means++	0.5208	0.5807
#14	random	0.5208	0.5807
#15	farthest-first	0.5208	0.5807
#16	k-means++	0.5208	0.5807
#17	random	0.5208	0.5807
#18	farthest-first	0.5208	0.5807
#19	k-means++	0.5208	0.5807
#20	random	0.5208	0.5807
АНСАМБЛЬ	**consensus**	**0.5208**	**0.5807**

Рисунок 3 – Результат запуска ансамбля

По результату размеры итоговых кластеров 1035 и 1965. Силуэт ансамбля 0,5208, ARI с реальными классами 0,5807, то есть как у лучших одиночных запусков. Попарное ARI между запусками в среднем 0,9997 (минимум 0,9973), разброс ARI относительно реальных классов 0,0002. Ансамбль не улучшил качество, потому что одиночный K-Means уже воспроизводим, но подтвердил его устойчивость.

b. DBSCAN

Проведем подбор гиперпараметров при помощи анализа k-расстояний.

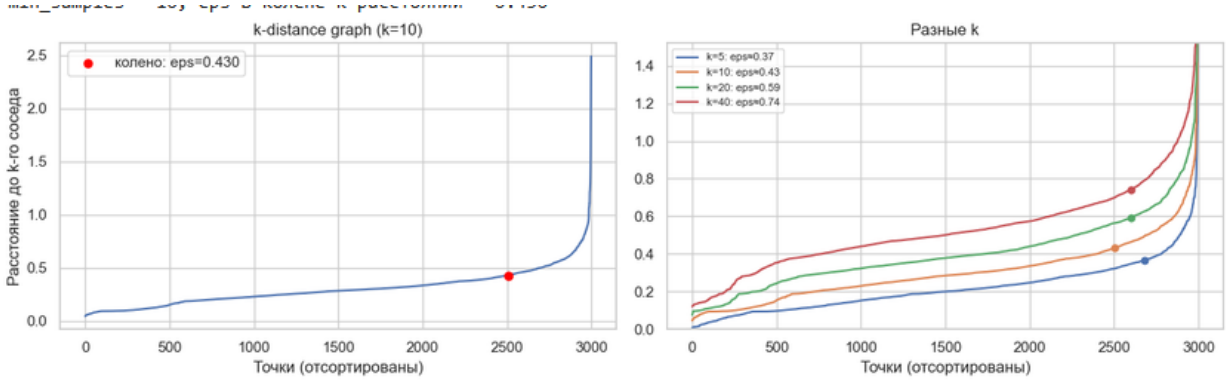


Рисунок 5 – График k-расстояний

Для min_samples=10 кривая отсортированных расстояний до k-го соседа почти плоская на уровне 0,1–0,5 и резко растет только на последних 5% точек. Колено соответствует eps≈0,43. Справа показаны кривые для k=5, 10, 20, 40, колена которых дают eps≈0,37, 0,43, 0,59 и 0,74. Чем больше min_samples, тем больше eps.

Далее выполним перебор сетки: eps умножался на коэффициенты от 0,5 до 2,0 для min_samples 5, 10, 20, 40.

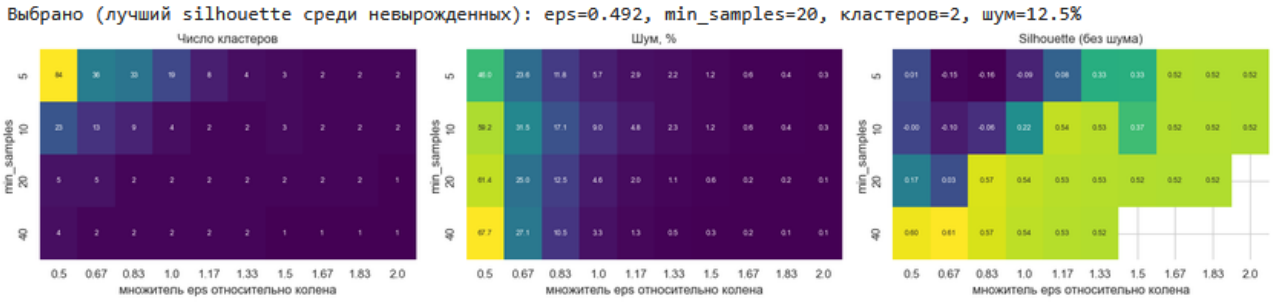


Рисунок 6 – Подбор гиперпараметров

Матрицы результатов отражены на рисунке 6. При малых eps получаются десятки мелких кластеров и до 67,7% шума. При больших eps все сливается в один кластер (пустые ячейки справа на панели силуэта). В качестве рабочей конфигурации выбрана лучшая по силуэту среди невырожденных, то есть с ≥2 кластерами, наименьшим кластером ≥2% и шумом ≤15%. Это eps=0,492 и min_samples=20: 2 кластера, 12,5% шума, силуэт 0,57.

Проведем исследование чувствительности алгоритма к шуму и выбросам. Для этого добавим выбросы и гауссовый шум (синтетически).

Влияние добавленных выбросов

	Тип	Доля выбросов	Кластеров	Шум всего, %	Шум среди исходных, %	Выбросов найдено, %	ARI DBSCAN vs чистый	ARI K-Means vs чистый
0	uniform	0.00	2	12.500	12.500	NaN	1.000	1.000
1	uniform	0.02	2	14.183	12.500	98.333	1.000	1.000
2	uniform	0.05	2	16.476	12.433	97.333	0.998	0.997
3	uniform	0.10	2	20.212	12.433	98.000	0.998	0.997
4	uniform	0.20	2	26.639	12.367	98.000	0.996	0.996
5	near	0.00	2	12.500	12.500	NaN	1.000	1.000
6	near	0.02	2	14.216	12.500	100.000	1.000	1.000
7	near	0.05	2	16.667	12.500	100.000	1.000	1.000
8	near	0.10	2	20.273	12.467	98.333	0.999	1.000
9	near	0.20	2	27.028	12.500	99.667	1.000	1.000

Влияние гауссова шума в признаках

	σ шума	Кластеров	Шум, %	ARI DBSCAN vs чистый	ARI DBSCAN vs y	ARI K-Means vs чистый
0	0.00	2	12.500	1.000	0.532	1.000
1	0.05	2	13.667	0.935	0.524	0.996
2	0.10	2	16.433	0.876	0.510	0.996
3	0.20	2	33.000	0.533	0.380	0.993
4	0.30	2	69.533	0.117	0.108	0.984
5	0.50	0	100.000	0.000	0.000	0.953

Влияние eps

	множитель	eps	Кластеров	Шум, %	min_share	ARI vs y
0	0.50	0.246	6	74.900	0.020	0.122
1	0.75	0.369	4	32.333	0.012	0.325
2	1.00	0.492	2	12.500	0.382	0.532
3	1.25	0.615	2	3.567	0.355	0.569
4	1.50	0.738	2	1.400	0.348	0.577
5	2.00	0.983	2	0.200	0.344	0.582

Рисунок 7 – Таблицы влияний выбросов и шума

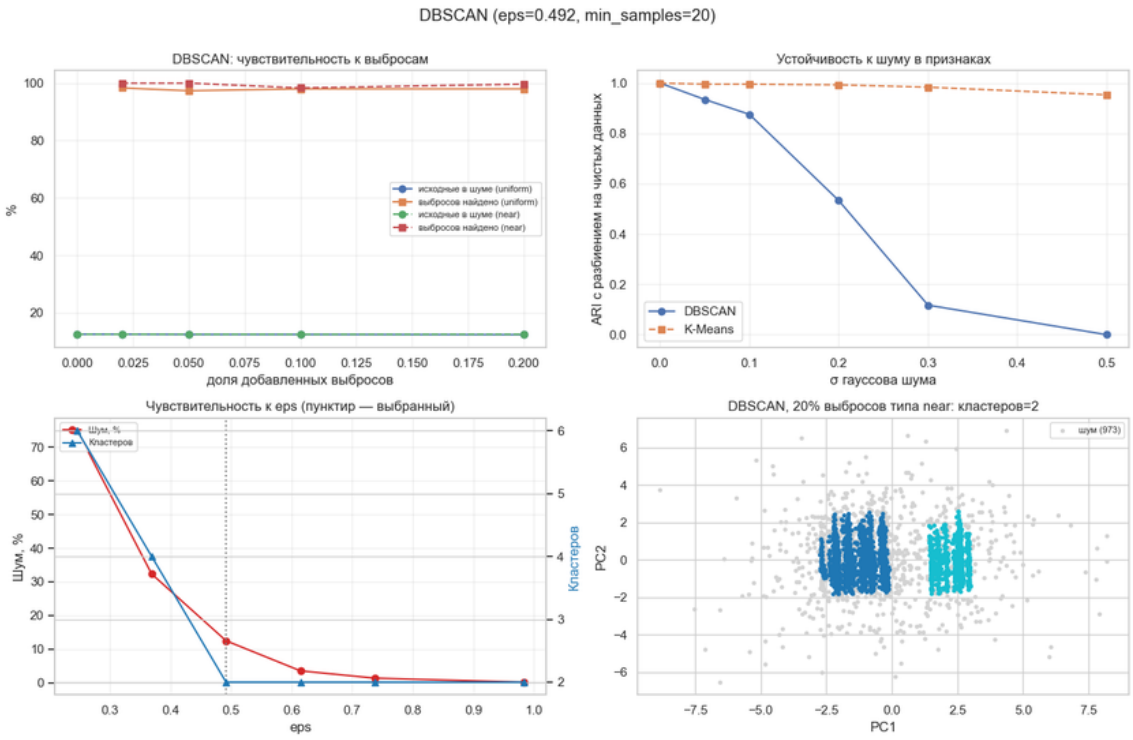


Рисунок 8 – Графики влияния на кластеризацию

Добавленные выбросы (до 20%) находятся в 97–100% случаев, доля исходных точек в шуме остается около 12,5%, ARI с разбиением на чистых данных не ниже 0,996. К гауссову шуму в признаках DBSCAN чувствительнее: при σ=0,1 ARI равен 0,88, при σ=0,2 0,53, при σ=0,3 0,12, а при σ=0,5 все точки становятся шумом. K-Means сохраняет ARI≥0,95 даже при σ=0,5. Уменьшение eps вдвое дает 6 кластеров и 74,9% шума, при eps≥1,25 от выбранного шум не превышает 3,6%.

c. Иерархическая кластеризация

Проведем кластеризацию с разными связями и метриками (9 комбинаций) для k от 2 до 8.

	config	cophenetic	silhouette (своя метрика)	silhouette (евклид)	min_share	ARI	NMI	time_s	valid
0	ward / euclidean	0.7976	0.5209	0.5209	0.3440	0.5822	0.7360	0.1583	True
1	complete / euclidean	0.8044	0.5209	0.5209	0.3440	0.5822	0.7360	0.1730	True
2	average / euclidean	0.8247	0.4955	0.4955	0.0003	0.0000	0.0007	0.2009	False
3	single / euclidean	0.7796	0.3470	0.3470	0.0003	0.0000	0.0007	0.1110	False
4	average / cityblock	0.8416	0.5821	0.5209	0.3440	0.5822	0.7360	0.1815	True
5	complete / cityblock	0.6350	0.3502	0.3117	0.4013	0.2548	0.2895	0.2029	True
6	average / cosine	0.8538	0.6710	0.5200	0.3447	0.5812	0.7315	0.1822	True
7	complete / cosine	0.6360	0.6714	0.5195	0.3453	0.5801	0.7276	0.1580	True
8	average / chebyshev	0.7160	0.4294	0.3409	0.0030	0.0000	0.0006	0.1605	False

Рисунок 9 – Таблица сравнения различных конфигураций

При k=2 ward/euclidean, complete/euclidean, average/cityblock, average/cosine и complete/cosine дают практически одинаковое разбиение (силуэт≈0,52, ARI≈0,58). Связи average/euclidean, single/euclidean и average/chebyshev вырождены (наименьший кластер 0,03%, ARI=0) и исключены из графика, complete/cityblock дает силуэт 0,31 и ARI 0,25. Лучшее кофенетическое соответствие у average/cosine (0,854), у ward 0,798. Итоговая конфигурация: ward/euclidean, k=2.

Далее определим оптимальное число кластеров по дендрограмме на рисунке 10.



Рисунок 10 – Подбор числа кластеров по дендрограмме

Последнее слияние происходит на высоте около 130, и скачок высоты при переходе от двух кластеров к одному (≈78) в разы больше остальных (≤10). Линия разреза (≈91) дает два кластера, как и по силуэту.

Следующим этапом проверим масштабируемость. Для этого сравним время выполнения при увеличении объема данных от 500 до 8000 объектов. Результат приведен на рисунке 11.

метод n	DBSCAN (база)	K-Means (база)	average/ cosine	average/ euclidean	complete/ euclidean	ward/ euclidean
500	0.006	0.015	0.007	0.008	0.007	0.008
1000	0.014	0.014	0.026	0.026	0.026	0.027
2000	0.034	0.009	0.104	0.104	0.098	0.128
4000	0.106	0.010	0.613	0.586	0.566	0.504
8000	0.282	0.011	3.002	2.678	2.893	2.127

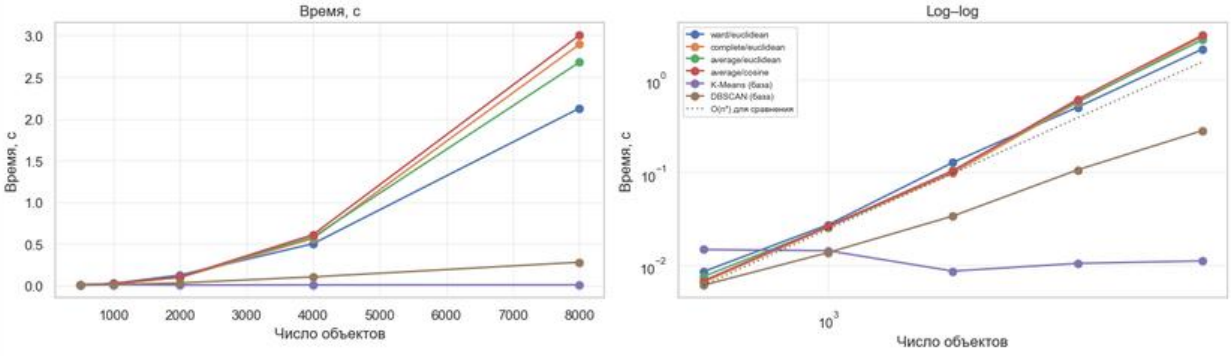


Рисунок 11 – Масштабируемость

При росте выборки с 500 до 8000 объектов время иерархической кластеризации растет с 0,01 до 2–3 с. Эмпирический показатель степени равен 2,0 для ward и 2,15–2,2 для остальных, то есть рост близок к квадратичному. У DBSCAN α=1,4 (0,28 с на 8000), время K-Means практически не зависит от n (~0,01 с). Для больших выборок иерархические методы без подвыборки непригодны.

3. Провести оценку моделей

а. Экспертная оценка

Экспертная оценка проводилась путем составления четырех профилей кластеров для каждой из моделей: K-Means (k=2), ансамбль K-Means (20 запусков), DBSCAN (eps=0.492, min_samples=20) и иерархическая кластеризация (ward/euclidean, k=2). Для каждого кластера были рассчитаны медианные значения числовых признаков, доля синтетических объектов, процентное соотношение реальных классов (Accessories, Bikes, Clothing), а

также наиболее частые категориальные значения (страна, пол, возрастная группа).

```
======== K-Means (k=2) ========
```

	n	доля, %	Customer_Age	Order_Quantity	Unit_Cost	Unit_Price	Revenue	синтетика, %	% Accessories	% Bikes	% Clothing	топ Country	топ Customer_Gender	топ Age_Group
K0	1965	65.5	34.0	15.0	8.0	22.0	181.0	37.9	50.4	0.0	49.6	United States (37%)	M (51%)	Adults (35-64) (49%)
K1	1035	34.5	34.0	1.0	1252.0	2295.0	2018.0	63.1	0.3	99.6	0.1	United States (34%)	F (52%)	Adults (35-64) (48%)

```
  K0: главные отличия от среднего — Unit_Cost (-0.65), Unit_Price (-0.65), Order_Quantity (+0.57)
  K1: главные отличия от среднего — Unit_Cost (+1.31), Unit_Price (+1.30), Order_Quantity (-1.13)

======== K-Means ансамбль (k=2, 20 запусков) ========
```

	n	доля, %	Customer_Age	Order_Quantity	Unit_Cost	Unit_Price	Revenue	синтетика, %	% Accessories	% Bikes	% Clothing	топ Country	топ Customer_Gender	топ Age_Group
K0	1035	34.5	34.0	1.0	1252.0	2295.0	2018.0	63.1	0.3	99.6	0.1	United States (34%)	F (52%)	Adults (35-64) (48%)
K1	1965	65.5	34.0	15.0	8.0	22.0	181.0	37.9	50.4	0.0	49.6	United States (37%)	M (51%)	Adults (35-64) (49%)

```
  K0: главные отличия от среднего — Unit_Cost (+1.31), Unit_Price (+1.30), Order_Quantity (-1.13)
  K1: главные отличия от среднего — Unit_Cost (-0.65), Unit_Price (-0.65), Order_Quantity (+0.57)

======== DBSCAN (eps=0.492, min_samples=20) ========
```

	n	доля, %	Customer_Age	Order_Quantity	Unit_Cost	Unit_Price	Revenue	синтетика, %	% Accessories	% Bikes	% Clothing	топ Country	топ Customer_Gender	топ Age_Group
шум	375	12.5	43.0	3.0	8.0	21.0	46.0	27.7	60.5	7.2	32.3	United States (41%)	M (55%)	Adults (35-64) (60%)
K0	1621	54.0	34.0	17.0	8.0	22.0	217.0	40.4	47.3	0.0	52.7	United States (36%)	M (50%)	Adults (35-64) (46%)
K1	1004	33.5	34.0	1.0	1252.0	2295.0	2024.0	63.6	0.0	100.0	0.0	United States (34%)	F (52%)	Adults (35-64) (47%)

```
  шум: главные отличия от среднего — Revenue (-1.11), Unit_Cost (-0.60), Unit_Price (-0.60)
  K0: главные отличия от среднего — Order_Quantity (+0.75), Unit_Cost (-0.63), Unit_Price (-0.63)
  K1: главные отличия от среднего — Unit_Cost (+1.31), Unit_Price (+1.31), Order_Quantity (-1.14)

======== Иерархическая (ward/euclidean, k=2) ========
```

	n	доля, %	Customer_Age	Order_Quantity	Unit_Cost	Unit_Price	Revenue	синтетика, %	% Accessories	% Bikes	% Clothing	топ Country	топ Customer_Gender	топ Age_Group
K0	1968	65.6	34.0	15.0	8.0	22.0	180.5	37.9	50.5	0.0	49.5	United States (37%)	M (51%)	Adults (35-64) (49%)
K1	1032	34.4	34.0	1.0	1252.0	2295.0	2024.0	63.3	0.0	99.9	0.1	United States (34%)	F (52%)	Adults (35-64) (48%)

```
  K0: главные отличия от среднего — Unit_Cost (-0.65), Unit_Price (-0.64), Order_Quantity (+0.56)
  K1: главные отличия от среднего — Unit_Cost (+1.31), Unit_Price (+1.30), Order_Quantity (-1.13)
```

Рисунок 12 – Распределение по итоговым кластерам

По результату на рисунке 12, мы видим следующую картину:

- K-Means разбил данные на два кластера. Кластер K0 объединил дешевые массовые товары: медианная цена Unit_Price = 22, себестоимость Unit_Cost = 8, количество в заказе Order_Quantity = 15. Кластер K1 – это дорогие штучные товары: цена 2295, себестоимость 1252, количество 1. Состав по реальным классам подтверждает интерпретацию: K1 на 99.6%

состоит из Bikes, а K0 – это смесь Accessories (50.4%) и Clothing (49.6%). Ансамбль K-Means дал абсолютно идентичный результат, только метки K0 и K1 поменялись местами (из-за порядка кластеров), что подтверждает устойчивость одиночного K-Means.

- DBSCAN выделил три группы: шум (12.5%), K0 (54%) и K1 (33.5%). Шум – это нетипичные покупки: медианный возраст 43 года (против 34 в кластерах), Revenue ниже среднего на 1.11 стандартного отклонения, состав – преимущественно Accessories (60.5%). Кластер K1 – это «чистые» Bikes (100%), с высокой ценой и количеством 1. Кластер K0 – Accessories + Clothing (47.3% и 52.7%). То есть DBSCAN, как и K-Means, разделяет данные по цене, но дополнительно отсекает нетипичные объекты в шум.
- Иерархическая кластеризация дала результат, практически совпадающий с K-Means: K0 (65.6%) – дешевые Accessories + Clothing (50.5% / 49.5%), K1 (34.4%) – Bikes (99.9%).

b. Сравнение разбиения на классы с помощью кластеризации с реальными.

Для количественной оценки того, насколько результаты кластеризации совпадают с истинными классами (Product_Category), использовался набор внешних метрик. В отличие от задач классификации, здесь нет единственной «правильной» метрики, поэтому оценка проводилась по нескольким критериям одновременно:

- ARI (Adjusted Rand Index) – скорректированный индекс Рэнда. Показывает степень совпадения пар объектов, попавших в один кластер и один класс.
- NMI (Normalized Mutual Information) – нормированная взаимная информация. Оценивает, сколько информации о реальном классе содержится в предсказанном.
- Однородность (Homogeneity) – насколько каждый кластер состоит из объектов только одного класса.

- Полнота (Completeness) – насколько объекты одного класса собраны в одном кластере.
- V-measure – гармоническое среднее между однородностью и полнотой.
- Fowlkes–Mallows – геометрическое среднее точности и полноты на уровне пар объектов.
- Purity – доля объектов, которые попали в кластер, где преобладает их истинный класс.

Результаты расчета метрик и матрицы сопряженности «кластеры vs реальные классы» приведены на рисунке 13.

Метод	ARI	NMI	Однородность	Полнота	V-measure	Fowlkes-Mallows	Purity	ARI (только реальные)	NMI (только реальные)	ARI (test)	NMI (test)	ARI (без шума)	Silhouette (без шума)	Шум, %
K-Means	0.581	0.729	0.578	0.985	0.729	0.778	0.674	0.645	0.727	0.634	0.738	0.581	0.521	0.000
K-Means ансамбль	0.581	0.729	0.578	0.985	0.729	0.778	0.674	0.645	0.727	0.634	0.738	0.581	0.521	0.000
DBSCAN	0.532	0.600	0.562	0.644	0.600	0.710	0.695	0.452	0.556	0.462	0.563	0.626	0.571	12.500
Иерархическая	0.582	0.736	0.584	0.996	0.736	0.779	0.675	0.651	0.742	0.634	0.738	0.582	0.521	0.000



Рисунок 13 – Тепловые карты сравнения кластеров и реальных классов

По сводной таблице метрик можно сделать следующие результаты:

K-Means (k=2) и K-Means ансамбль показали абсолютно идентичные результаты. Высокая полнота при умеренной однородности означает, что кластеры «собирают» почти все объекты своих классов, но при этом смешивают Accessories и Clothing в одном кластере. Ансамбль не улучшил метрики, но подтвердил, что одиночный K-Means воспроизводим.

Иерархическая кластеризация дала лучшие результаты среди всех моделей. Практически полная полнота (0.996) говорит о том, что каждый реальный класс почти целиком попадает в один кластер.

DBSCAN уступает по внешним метрикам, что объясняется наличием 12.5% шума: шумовые точки не относятся ни к одному кластеру и формально не участвуют в сравнении.

Значения ARI и NMI на реальных объектах (без синтетики) для K-Means и иерархической кластеризации даже выше, чем на полной выборке. Это означает, что синтетические объекты SMOTE-NC немного «размывают» границы кластеров, но не искажают общую картину.

Четыре тепловые карты показывают, как кластеры соотносятся с реальными классами. Модель K-Means идеально выделила Bikes, но не смогла разделить Accessories и Clothing. Для модели K-Means ансамбль та же картина, но K0 и K1 поменялись местами (1031 Bikes в K0, 990 + 975 в K1). Это еще раз подтверждает, что ансамбль не изменил разбиение. DBSCAN: появляется третья строка – «шум». Иерархическая кластеризация практически совпадает с K-Means, но Bikes чуть чище.

c. Визуализация предсказанных значений

Для наглядного сравнения результатов работы алгоритмов и их соответствия реальной структуре данных была построена двумерная проекция методом t-SNE. В отличие от линейного метода главных компонент (PCA), t-SNE сохраняет локальные нелинейные связи между объектами, что позволяет визуально оценить, насколько хорошо алгоритмы разделяют близкие и далекие группы. В результате построены диаграммы графики на рисунке 14.

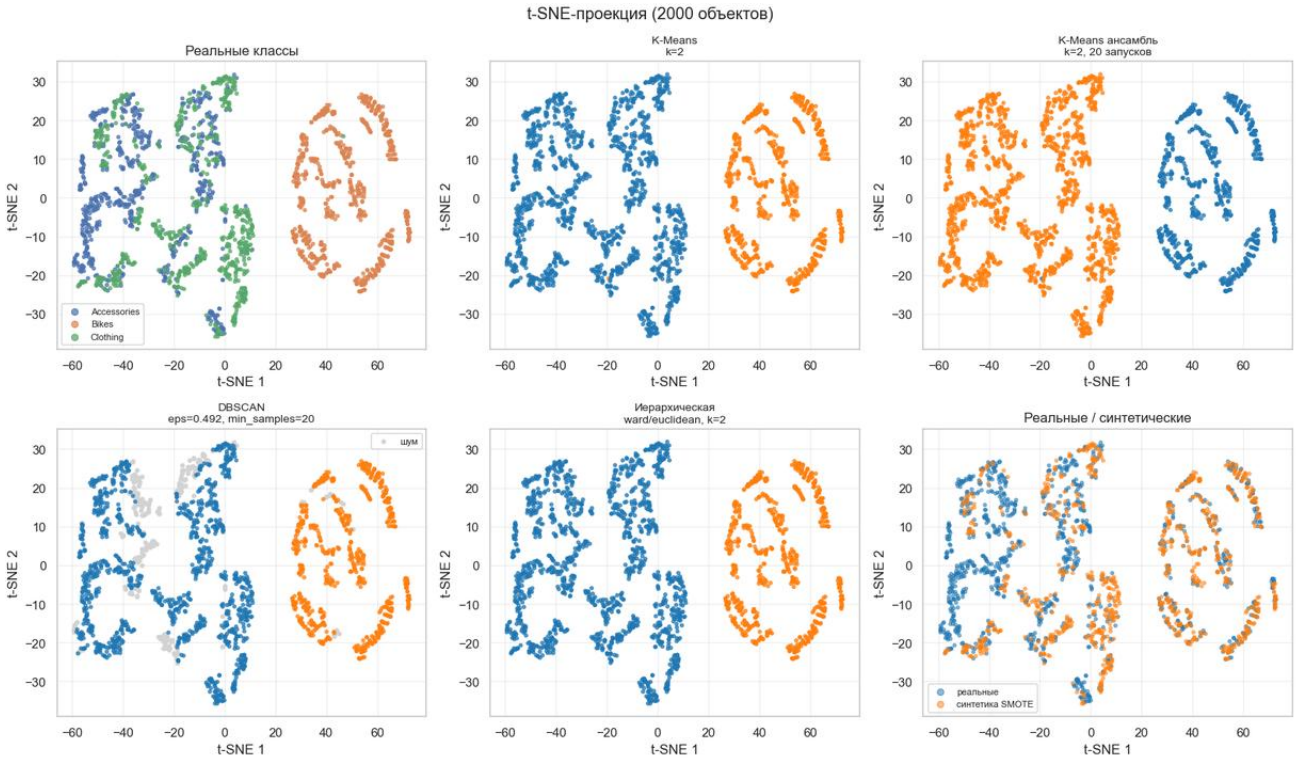


Рисунок 14 – Диаграмма рассеяния t-SNE

По результату на рисунке мы видим следующее. На проекции t-SNE для реальных классов данные четко разделены на три обособленные группы. Accessories (синие) и Bikes (оранжевые) образуют отдельные плотные сгустки, а Clothing (зеленые) расположены в левой нижней части. При этом Accessories и Bikes визуально находятся ближе друг к другу, чем к Clothing, что объясняет, почему алгоритмы при k=2 склонны объединять их в один кластер.

Для K-Means (k=2) и K-Means ансамбль (20 запусков) видно разделение на два крупных кластера: один кластер (синий на первой панели, оранжевый на второй) объединяет Accessories и Bikes, второй кластер (оранжевый на первой панели, синий на второй) полностью соответствует Clothing. Это визуально подтверждает выводы из матриц сопоставления: K-Means «склеивает» две близкие категории (Accessories и Bikes) в один кластер, но идеально выделяет Clothing. Границы между кластерами проходят достаточно четко, без значительного смешения точек. Ансамбль дал точно такую же картину (только цвета кластеров инвертированы), что подтверждает устойчивость алгоритма.

DBSCAN выделил те же два крупных кластера, что и K-Means, но дополнительно пометил часть точек как шум (серые точки). Шумовые объекты расположены по краям кластеров и в пространстве между ними – это пограничные или нетипичные покупки. Кластеры DBSCAN выглядят более плотными и компактными, что согласуется с более высоким значением силуэта (0.571). Однако наличие шума «разрывает» часть данных, что снижает общий ARI по сравнению с K-Means.

Иерархическая кластеризация почти неотличима от K-Means: те же два кластера, те же границы. Это подтверждает, что метод Уорда минимизирует внутрикластерную дисперсию так же, как и K-Means, и при k=2 приводит к аналогичному разбиению.

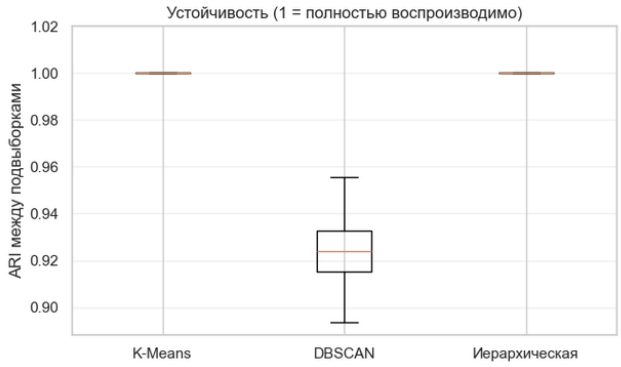
d. Провести кросс-валидацию устойчивости кластеров через многократную подвыборку данных

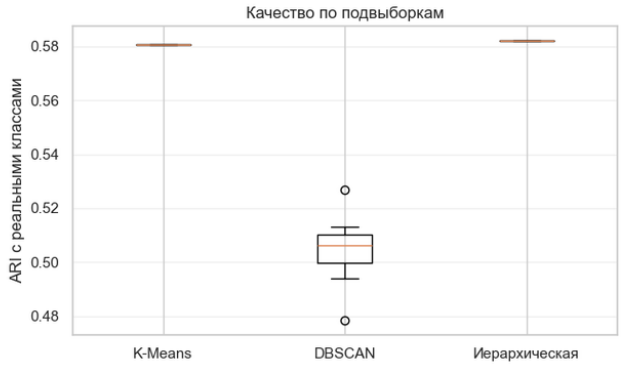
Для проверки того, насколько стабильно алгоритмы находят одну и ту же структуру данных, была проведена кросс-валидация через многократную подвыборку. Суть метода заключается в следующем: из исходной выборки Xs (3000 объектов) 20 раз случайно извлекается 80% объектов (подвыборка). На каждой такой подвыборке модель обучается заново, после чего вычисляется попарный ARI (Adjusted Rand Index) между разбиениями, полученными на разных итерациях.

Если алгоритм устойчив, то объекты, попавшие в один кластер на одной итерации, с высокой вероятностью окажутся в одном кластере и на другой. Значение ARI = 1.0 означает полную воспроизводимость разбиения, а значение около 0 – случайное совпадение.

Устойчивость: 20 подвыборок по 80%, попарное ARI на всех объектах Xs

Метод	Стабильность ARI (mean)	std	min	ARI vs y (mean)	ARI vs y (std)	Кластеров (mean)	Кластеров (std)
K-Means	1.000	0.000	1.000	0.581	0.000	2.000	0.000
DBSCAN	0.924	0.013	0.894	0.505	0.009	2.100	0.300
Иерархическая	1.000	0.000	1.000	0.582	0.000	2.000	0.000





	Параметры	Кластеров	Шум, %	Мин. кластер, %	Silhouette	ARI	NMI	ARI (реальные)	ARI (test)	Устойчивость ARI	Время fit, с
DBSCAN	eps=0.492, min_samples=20	2.000	12.500	38.248	0.571	0.532	0.600	0.452	0.462	0.924	0.055
K-Means	k=2	2.000	0.000	34.500	0.521	0.581	0.729	0.645	0.634	1.000	0.019
K-Means ансамбль	k=2, 20 запусков	2.000	0.000	34.500	0.521	0.581	0.729	0.645	0.634	—	—
Иерархическая	ward/euclidean, k=2	2.000	0.000	34.400	0.521	0.582	0.736	0.651	0.634	1.000	0.218

Рисунок 15 – Проверка устойчивости кластеризации

K-Means и иерархическая кластеризация демонстрируют идеальную устойчивость: средний ARI между подвыборками равен 1.000 при стандартном отклонении 0.000. Это означает, что на любой случайной подвыборке 80% модель воспроизводит абсолютно идентичное разбиение. Число кластеров стабильно равно 2.0 (std = 0.000).

DBSCAN менее устойчив: средний ARI между подвыборками составляет 0.924, а стандартное отклонение – 0.013. Минимальное значение падает до 0.894. Число кластеров варьируется (2.100 ± 0.300). Это объясняется тем, что DBSCAN чувствителен к плотности: при удалении 20% точек некоторые области перестают удовлетворять условию min_samples, и объекты переходят в шум или меняют кластер.

По диаграммам видно, что «ящики» для K-Means и иерархической кластеризации вырождены в горизонтальные линии на уровне 1.000 — разброса нет вообще. У DBSCAN ящик растянут от ~0.91 до ~0.94, что визуально подтверждает разброс.

Справа (Качество по подвыборкам, ARI с реальными классами): K-Means и иерархическая кластеризация показывают стабильные значения 0.581 и 0.582 (линии без разброса). У DBSCAN ящик расположен ниже (около 0.505), с выбросами от 0.48 до 0.53. Это означает, что качество DBSCAN не только ниже в среднем, но и сильнее «прыгает» в зависимости от того, какие данные попали в подвыборку.

Итоговая таблица объединяет параметры моделей, число кластеров, долю шума, Silhouette, ARI/NMI, ARI на тестовой выборке, устойчивость и время работы. Кросс-валидация через многократную подвыборку показала, что K-Means и иерархическая кластеризация обладают абсолютной устойчивостью к изменению состава данных (ARI = 1.000). Они всегда находят одно и то же разбиение на два кластера. DBSCAN менее устойчив (ARI = 0.924), так как его результат зависит от локальной плотности точек: при удалении части данных границы кластеров и состав шума меняются. Однако стоит отметить, что даже у DBSCAN средний ARI остается достаточно высоким (0.924), что говорит о том, что основная структура данных (разделение Bikes и остальных) сохраняется. Для данного датасета наиболее надежным и стабильным выбором являются K-Means и иерархическая кластеризация, при этом K-Means выигрывает по скорости.

Выводы

В ходе лабораторной работы освоены и применены на практике методы кластеризации: K-Means (включая ансамблевую схему), DBSCAN и иерархическая кластеризация.

Для данного датасета при отсутствии априорного знания о числе классов оптимальным компромиссом между качеством, скоростью и устойчивостью является K-Means с k = 2 (или его ансамбль), а иерархическая кластеризация ward/euclidean может использоваться как эталон качества при небольших объемах данных. DBSCAN целесообразен, когда важно автоматически

выделить шум и кластеры сложной формы, однако требует тщательного подбора eps и min_samples и менее устойчив к шуму в признаках.